

Stili di gioco e gruppi di lavoro bilanciati

PCA, metodo delle potenze e decomposizione della varianza applicati a una squadra di rugby

Matteo Guerrucci

Progetto di Analisi Numerica — settembre 2026

Sommario

Una rosa di $N = 25$ giocatori è descritta da $D = 10$ statistiche per 80 minuti. Con l'analisi delle componenti principali (PCA) si individuano pochi *assi di stile di gioco*; le componenti sono calcolate con un metodo delle potenze implementato da zero, con deflazione, e verificate contro la SVD. Nello spazio degli stili si formano poi 5 gruppi di lavoro *bilanciati* minimizzando la varianza tra i gruppi: per la decomposizione della varianza questo equivale a mescolare in ogni gruppo giocatori forti e deboli su ogni asse. I dati sono sintetici.

1 Richiami: valore atteso, varianza, covarianza

Riferimento: M. P. Deisenroth, A. A. Faisal, C. S. Ong, *Mathematics for Machine Learning*, Cambridge University Press, 2020 (cap. 6, statistiche riassuntive; cap. 10, PCA). Il libro usa la convenzione $X \in \mathbb{R}^{D \times N}$ (dati per colonne) e il fattore $1/N$; qui $X \in \mathbb{R}^{N \times D}$ (una riga per giocatore) e $1/(N-1)$, lo stimatore non distorto.

Valore atteso e varianza. Per una variabile aleatoria x con media $\mu = \mathbb{E}[x]$:

$$\mathbb{V}[x] = \mathbb{E}[(x - \mu)^2] = \mathbb{E}[x^2] - (\mathbb{E}[x])^2, \quad \sigma = \sqrt{\mathbb{V}[x]} \quad (\text{deviazione standard}).$$

Per un vettore aleatorio $\mathbf{x} \in \mathbb{R}^D$ con media $\boldsymbol{\mu}$, la matrice di covarianza è

$$\Sigma = \text{Cov}[\mathbf{x}] = \mathbb{E}[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T], \quad \Sigma_{ij} = \text{Cov}[x_i, x_j], \quad \Sigma_{jj} = \mathbb{V}[x_j].$$

Versioni empiriche. Da N osservazioni $\mathbf{x}_1, \dots, \mathbf{x}_N$:

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_n \mathbf{x}_n, \quad C = \frac{1}{N-1} \sum_n (\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^T = \frac{1}{N-1} X^T X \quad (X \text{ centrata}).$$

Perché si centra prima: un fatto numerico. Le due espressioni della varianza sono uguali in aritmetica esatta, ma non in floating point. $\mathbb{E}[x^2] - (\mathbb{E}[x])^2$ sottrae due numeri grandi e quasi uguali: è una **cancellazione catastrofica**. Con i valori $\{4, 7, 13, 16\}$ (varianza esatta 22.5) spostati di 10^9 , la formula a una passata dà -128 (una varianza negativa), quella a due passate $\mathbb{E}[(x - \mu)^2]$ dà 22.5. Per questo il codice centra sempre i dati prima di calcolare C .

Trasformazioni lineari. Se $\mathbf{y} = A\mathbf{x} + \mathbf{c}$, allora

$$\mathbb{E}[\mathbf{y}] = A\boldsymbol{\mu} + \mathbf{c}, \quad \text{Cov}[\mathbf{y}] = A \Sigma A^T.$$

In particolare, per la proiezione su una direzione $\mathbf{b}$ ($A = \mathbf{b}^T$):

$$\boxed{\mathbb{V}[\mathbf{b}^T \mathbf{x}] = \mathbf{b}^T \Sigma \mathbf{b}}$$

è il punto di partenza della PCA: la varianza lungo una direzione è una forma quadratica nella matrice di covarianza. Con B^T al posto di $\mathbf{b}^T$: $\text{Cov}[B^T \mathbf{x}] = B^T \Sigma B$.

Geometria delle variabili aleatorie. Per variabili a media nulla, $\langle x, y \rangle := \text{Cov}[x, y]$ è un prodotto scalare. La norma indotta è la deviazione standard, $\|x\| = \sqrt{\text{Cov}[x, x]} = \sigma_x$, e

$$\cos \theta = \frac{\langle x, y \rangle}{\|x\| \|y\|} = \frac{\text{Cov}[x, y]}{\sigma_x \sigma_y} = \rho(x, y),$$

cioè la **correlazione** è il **coseno dell'angolo** tra le due variabili. Variabili **scorrelate** sono **ortogonali**. In questa geometria la PCA cerca direzioni ortogonali: gli score lungo componenti diverse sono scorrelati, perché $\text{Cov}[\mathbf{b}_i^T \mathbf{x}, \mathbf{b}_j^T \mathbf{x}] = \mathbf{b}_i^T \Sigma \mathbf{b}_j = \lambda_j \mathbf{b}_i^T \mathbf{b}_j = 0$ per $i \neq j$. Inoltre $\text{tr}(\Sigma) = \sum_j \mathbb{V}[x_j]$ è la varianza totale (la somma dei quadrati delle “lunghezze” delle variabili).

2 Dati e standardizzazione

Sia $X_{\text{raw}} \in \mathbb{R}^{N \times D}$ la matrice dei dati (una riga per giocatore). Ogni colonna viene centrata e divisa per la sua deviazione standard:

$$X_{nj} = \frac{(X_{\text{raw}})_{nj} - \mu_j}{\sigma_j}.$$

Senza standardizzazione le statistiche con valori grandi (metri guadagnati ≈ 50) dominerebbero quelle con valori piccoli (offload ≈ 1) solo per una questione di unità di misura.

Matrice di covarianza.

$$C = \frac{1}{N-1} X^T X \in \mathbb{R}^{D \times D}.$$

Con dati standardizzati C è la matrice di correlazione: $C_{jj} = 1$ e $\text{tr}(C) = D$. C è **simmetrica** e **semidefinita positiva**; per il teorema spettrale ha autovalori reali $\lambda_1 \geq \dots \geq \lambda_D \geq 0$ e autovettori ortonormali.

Lettura geometrica. Per colonne centrate a, b , la covarianza $\text{cov}(a, b) = a^T b / (N-1)$ è un prodotto scalare, la deviazione standard è la norma associata e la correlazione $\rho = \text{cov}(a, b) / (\sigma_a \sigma_b)$ è il **coseno dell'angolo** tra le due colonne. La nuvola dei giocatori in $\mathbb{R}^D$ ha la forma di un ellissoide: gli autovettori di C ne sono gli assi, gli autovalori la varianza lungo ciascun asse.

3 PCA come problema di massima varianza

Si cerca una base ortonormale $B = [\mathbf{b}_1, \dots, \mathbf{b}_M] \in \mathbb{R}^{D \times M}$, $B^T B = I$ ($\mathbf{b}_i^T \mathbf{b}_j = \delta_{ij}$), e si proiettano i dati: $\mathbf{z}_n = B^T \mathbf{x}_n$.

Varianza lungo una direzione. Se $z_n = \mathbf{b}^T \mathbf{x}_n$, allora

$$\text{Var}(z) = \frac{1}{N-1} \sum_n z_n^2 = \frac{1}{N-1} (X\mathbf{b})^T (X\mathbf{b}) = \mathbf{b}^T C \mathbf{b}.$$

3.1 Prima componente

$$\max_{\mathbf{b}} \mathbf{b}^T C \mathbf{b} \quad \text{con} \quad \mathbf{b}^T \mathbf{b} = 1.$$

Lagrangiana: $L(\mathbf{b}, \lambda) = \mathbf{b}^T C \mathbf{b} + \lambda(1 - \mathbf{b}^T \mathbf{b})$. Poiché C è simmetrica, $\nabla_{\mathbf{b}}(\mathbf{b}^T C \mathbf{b}) = (C + C^T)\mathbf{b} = 2C\mathbf{b}$, quindi

$$\frac{\partial L}{\partial \mathbf{b}} = 2C\mathbf{b} - 2\lambda\mathbf{b} = 0 \implies C\mathbf{b} = \lambda\mathbf{b}, \quad \frac{\partial L}{\partial \lambda} = 1 - \mathbf{b}^T \mathbf{b} = 0.$$

I punti stazionari sono gli autovettori (normalizzati) di C . Moltiplicando $C\mathbf{b} = \lambda\mathbf{b}$ per $\mathbf{b}^T$:

$$\mathbf{b}^T C \mathbf{b} = \lambda \mathbf{b}^T \mathbf{b} = \lambda,$$

cioè **la varianza lungo un autovettore è il suo autovalore**. Il massimo si ottiene con l'autovalore più grande λ_1 : $\mathbf{b}_1$ è la prima componente principale.

3.2 Seconda componente

$$\begin{aligned} \max_{\mathbf{b}_2} \mathbf{b}_2^T C \mathbf{b}_2 \quad \text{con} \quad \mathbf{b}_2^T \mathbf{b}_2 = 1, \quad \mathbf{b}_2^T \mathbf{b}_1 = 0. \\ L = \mathbf{b}_2^T C \mathbf{b}_2 + \lambda_2(1 - \mathbf{b}_2^T \mathbf{b}_2) - \mu \mathbf{b}_2^T \mathbf{b}_1, \quad \frac{\partial L}{\partial \mathbf{b}_2} = 2C\mathbf{b}_2 - 2\lambda_2\mathbf{b}_2 - \mu\mathbf{b}_1 = 0. \end{aligned}$$

Moltiplicando a sinistra per $\mathbf{b}_1^T$: il primo termine dà $2\mathbf{b}_1^T C \mathbf{b}_2 = 2(C\mathbf{b}_1)^T \mathbf{b}_2 = 2\lambda_1 \mathbf{b}_1^T \mathbf{b}_2 = 0$, il secondo $-2\lambda_2 \mathbf{b}_1^T \mathbf{b}_2 = 0$, il terzo $-\mu \mathbf{b}_1^T \mathbf{b}_1 = -\mu$. Quindi $\mu = 0$ e $C\mathbf{b}_2 = \lambda_2 \mathbf{b}_2$. Poiché $\mathbf{b}_2 \perp \mathbf{b}_1$, tra gli autovettori rimasti il massimo è λ_2 (supponendo $\lambda_1 > \lambda_2$). Per induzione, la j -esima componente è l'autovettore di λ_j .

3.3 Varianza spiegata

La varianza totale non dipende dalla base ortonormale:

$$\sum_{j=1}^D \text{Var}(X_{:,j}) = \text{tr}(C) = \sum_{j=1}^D \lambda_j.$$

La frazione spiegata dalle prime M componenti è $\sum_{j \leq M} \lambda_j / \sum_j \lambda_j$.

3.4 Legame con la SVD

Se $X = U\Sigma V^T$, allora $X^T X = V\Sigma^2 V^T$, quindi

$$\lambda_j = \frac{\sigma_j^2}{N-1}, \quad \mathbf{b}_j = \text{colonna } j \text{ di } V.$$

In pratica si preferisce la SVD di X al calcolo degli autovalori di $X^T X$ perché $K_2(X^T X) = K_2(X)^2$: formare $X^T X$ eleva al quadrato il numero di condizionamento.

3.5 Seconda lettura: minimo errore di ricostruzione

La PCA si può ottenere anche senza parlare di varianza (MML, par. 10.3). Proietto ogni $\mathbf{x}_n$ sul sottospazio generato da B e lo ricostruisco: $\tilde{\mathbf{x}}_n = BB^T \mathbf{x}_n$ (BB^T è il proiettore ortogonale). Cerco la base che rende minimo l'errore medio di ricostruzione

$$J_M = \frac{1}{N-1} \sum_n \|\mathbf{x}_n - \tilde{\mathbf{x}}_n\|^2.$$

Per Pitagora, $\|\mathbf{x}_n\|^2 = \|\tilde{\mathbf{x}}_n\|^2 + \|\mathbf{x}_n - \tilde{\mathbf{x}}_n\|^2$, quindi

$$\underbrace{\frac{1}{N-1} \sum_n \|\mathbf{x}_n\|^2}_{\text{tr}(C) \text{ (fissa)}} = \underbrace{\sum_{j \leq M} \mathbf{b}_j^T C \mathbf{b}_j}_{\text{varianza catturata}} + J_M.$$

Minimizzare l'errore di ricostruzione equivale a massimizzare la varianza catturata: le due letture danno la **stessa** base, e all'ottimo

$$J_M = \sum_{j > M} \lambda_j,$$

la somma degli autovalori scartati. È la stessa affermazione di Eckart–Young (Sezione 7), scritta con gli autovalori di C invece che con i valori singolari di X .

I passi della PCA in pratica (MML, par. 10.6): (1) sottrarre la media; (2) dividere per la deviazione standard; (3) calcolare autovalori e autovettori di C (o la SVD di X); (4) proiettare, $\mathbf{z}_n = B^T \mathbf{x}_n$; (5) per tornare nello spazio originale, $\tilde{\mathbf{x}}_n = B\mathbf{z}_n$, poi moltiplicare per σ_j e aggiungere μ_j .

Osservazione. Se i giocatori fossero meno delle statistiche ($N < D$), C avrebbe al più $N - 1$ autovalori non nulli, e conviene lavorare con la matrice $N \times N$ XX^T : se $XX^T \mathbf{u} = \mu \mathbf{u}$ allora $X^T X(X^T \mathbf{u}) = \mu X^T \mathbf{u}$ (MML, par. 10.5). Con $N = 25$, $D = 10$ non serve.

4 Metodo delle potenze

Algoritmo.

```

 $\mathbf{v} \leftarrow \mathbf{v}_0 / \|\mathbf{v}_0\|$    ( $\mathbf{v}_0$  casuale)
per  $k = 1, 2, \dots$ :    $\mathbf{w} = C\mathbf{v}$ ;    $\lambda^{(k)} = \mathbf{v}^T \mathbf{w}$ ;    $\mathbf{v} \leftarrow \mathbf{w} / \|\mathbf{w}\|$ 
stop se  $|\lambda^{(k)} - \lambda^{(k-1)}| < \text{tol} \cdot |\lambda^{(k)}|$ 

```

Il quoziente di Rayleigh $\lambda^{(k)} = \mathbf{v}^T C \mathbf{v}$ (con $\|\mathbf{v}\| = 1$) si ottiene dallo stesso prodotto $\mathbf{w} = C\mathbf{v}$: un solo prodotto matrice-vettore per iterazione. Il vettore iniziale casuale ha, con probabilità 1, una componente non nulla lungo $\mathbf{b}_1$.

Convergenza. Scriviamo $\mathbf{v}_0 = \sum_i c_i \mathbf{b}_i$ con $c_1 \neq 0$. Allora

$$C^k \mathbf{v}_0 = \sum_i c_i \lambda_i^k \mathbf{b}_i = c_1 \lambda_1^k \left(\mathbf{b}_1 + \sum_{i \geq 2} \frac{c_i}{c_1} \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{b}_i \right).$$

Se $|\lambda_2| < |\lambda_1|$ la direzione converge a $\mathbf{b}_1$ con errore $O(|\lambda_2/\lambda_1|^k)$. Poiché C è simmetrica, l'errore sul quoziente di Rayleigh è $O(|\lambda_2/\lambda_1|^{2k})$. La velocità dipende dal **distacco** tra i primi due autovalori: se $\lambda_2 \approx \lambda_1$ la convergenza è lenta; se $\lambda_2 = \lambda_1$ non c'è una direzione privilegiata.

Deflazione.

$$C_1 = C - \lambda_1 \mathbf{b}_1 \mathbf{b}_1^T.$$

Per l'ortonormalità degli autovettori, $C_1 \mathbf{b}_1 = 0$ e $C_1 \mathbf{b}_i = \lambda_i \mathbf{b}_i$ per $i \geq 2$: il metodo delle potenze su C_1 converge a $\mathbf{b}_2$, con velocità $|\lambda_3/\lambda_2|$. La deflazione è la versione numerica del vincolo $\mathbf{b}_2 \perp \mathbf{b}_1$ della lagrangiana.

Risultati.

j	λ_j (potenze)	rapporto che comanda	iterazioni
1	3.94498513	$\lambda_2/\lambda_1 = 0.75$	58
2	2.97239586	$\lambda_3/\lambda_2 = 0.35$	16
3	1.04652146	$\lambda_4/\lambda_3 = 0.70$	39

Gli autovalori coincidono con quelli della SVD fino all'ultima cifra mostrata. Il fattore di riduzione dell'errore misurato per $\mathbf{b}_1$ è 0.760, contro il valore teorico $\lambda_2/\lambda_1 = 0.754$ (Figura 1). Le prime tre componenti spiegano il 79.6% della varianza.

Osservazione. Il criterio d'arresto è sull'autovalore, che converge con velocità doppia: quando $\lambda^{(k)}$ è esatto a 10^{-12} , l'autovettore lo è solo a circa 10^{-6} . Se serve l'autovettore preciso ci si ferma sul residuo $\|C\mathbf{v} - \lambda\mathbf{v}\|$.




Figura 1: Errore del metodo delle potenze per $\mathbf{b}_1$: le curve sono parallele alle rette teoriche $|\lambda_2/\lambda_1|^k$ (autovettore) e $|\lambda_2/\lambda_1|^{2k}$ (Rayleigh).

5 Accelerare il metodo: shift e potenze inverse

Shift. $C - \sigma I$ ha gli stessi autovettori e autovalori $\lambda_i - \sigma$. Per $\mathbf{b}_1$ il rapporto di convergenza diventa $\max_{i \geq 2} |\lambda_i - \sigma|/|\lambda_1 - \sigma|$, minimo per $\sigma^* = (\lambda_2 + \lambda_D)/2$. Con i nostri dati $\sigma^* = 1.504$: il rapporto scende da 0.753 a 0.601 e le iterazioni da 47 a 29.

Potenze inverse con shift. $(C - \sigma I)^{-1}$ ha autovalori $1/(\lambda_i - \sigma)$: domina l'autovalore più vicino a σ , con rapporto $|\lambda_j - \sigma|/|\lambda_{\text{vicino}} - \sigma|$. Non si calcola l'inversa: a ogni passo si risolve $(C - \sigma I)\mathbf{w} = \mathbf{v}$. La fattorizzazione *LU* (con pivoting) si calcola **una volta**, e ogni iterazione costa due sostituzioni triangolari, $O(D^2)$ invece di $O(D^3)$.

cerco	σ	rapporto	iterazioni	errore su λ
λ_1	3.8	0.175	9	$2 \cdot 10^{-14}$
λ_2	3.0	0.029	5	$3 \cdot 10^{-15}$
λ_3	1.0	0.171	8	$1 \cdot 10^{-14}$
λ_{10}	0	0.476	20	$2 \cdot 10^{-15}$

Con $\sigma = 0$ si ottiene l'autovalore più piccolo (potenze inverse “pure”). Scegliendo σ si può calcolare *qualunque* autovalore, senza deflazione.

A cosa serve nel progetto: il condizionamento. Con una matrice 10×10 la velocità non è un problema. L'uso concreto è un altro: metodo delle potenze e potenze inverse con $\sigma = 0$ danno gli autovalori estremi, e per una matrice simmetrica definita positiva

$$K_2(C) = \frac{\lambda_{\max}}{\lambda_{\min}} = \frac{3.945}{0.0364} = 108.4, \quad K_2(X) = \frac{\sigma_{\max}}{\sigma_{\min}} = 10.41, \quad K_2(X)^2 = 108.4.$$

È la verifica numerica di $K_2(X^T X) = K_2(X)^2$ e quantifica perché si preferisce la SVD di X . Inoltre $\lambda_{\min} \approx 0$ dice che lungo $\mathbf{b}_{10}$ i giocatori quasi non variano: esiste una combinazione di statistiche quasi costante, cioè statistiche quasi ridondanti.

6 Affidabilità degli assi

Si perturbano i dati con rumore gaussiano pari al 10% della deviazione standard (300 prove) e si misura l'angolo tra ogni autovettore originale e quello perturbato.

asse	λ_j	gap con il vicino	rotazione mediana	rotazione 90%
$\mathbf{b}_1$	3.945	0.973	2.5°	5.1°
$\mathbf{b}_2$	2.972	0.973	2.9°	5.3°
$\mathbf{b}_3$	1.047	0.318	5.3°	9.2°
$\mathbf{b}_4$	0.728	0.178	8.3°	13.6°

Più il gap tra un autovalore e i suoi vicini è piccolo, più l'autovettore è **mal condizionato**: una piccola perturbazione dei dati lo fa ruotare molto. Al limite $\lambda_j = \lambda_{j+1}$ l'autovettore non è nemmeno definito (qualunque direzione del piano è un autovettore). È lo stesso gap che governa la velocità del metodo delle potenze: *convergenza lenta e instabilità hanno la stessa causa*. Per questo si interpretano solo $\mathbf{b}_1$ e $\mathbf{b}_2$.




Figura 2: Rotazione degli autovettori con rumore del 10% sui dati: cresce al diminuire del gap.

7 Rango k e dati mancanti

Eckart–Young. Tra le matrici di rango k , la più vicina a X è $X_k = U_k \Sigma_k V_k^T$, con

$$\|X - X_k\|_2 = \sigma_{k+1}, \quad \|X - X_k\|_F = \left(\sum_{i>k} \sigma_i^2 \right)^{1/2}.$$

Verificato numericamente per ogni k . Poiché $\sum_i \sigma_i^2 = \|X\|_F^2$, vale $(\|X - X_k\|_F / \|X\|_F)^2 = 1 - \text{varianza spiegata}$: con $k = 3$ l'errore relativo è $45\% = \sqrt{1 - 0.796}$.

Imputazione (i dati “disordinati”). Due giocatori hanno 4 statistiche mancanti. Invece di sostituirle con la media, si usa la struttura di basso rango: le statistiche sono correlate, quindi quelle osservate informano su quelle mancanti. Iterazione di punto fisso: si parte con i buchi uguali alla media; a ogni passo si calcola l'approssimazione di rango k e si sostituiscono *solo* i valori mancanti con quelli ricostruiti; ci si ferma quando i valori imputati non cambiano più. Errore sui valori mancanti (RMSE, in deviazioni standard):

metodo	media	$k = 1$	$k = 2$	$k = 3$	$k = 4$
RMSE	1.19	0.95	0.75	0.96	3.16 (non converge)

Con k piccolo l'imputazione migliora la media del 37%. Con k troppo grande il modello ha abbastanza libertà da adattarsi ai dati osservati senza vincolare quelli mancanti: il punto fisso diventa lentissimo o non converge e l'errore esplode. La convergenza, quando c'è, è lineare (fattore 0.915 per $k = 3$).




Figura 3: Sopra: autovalori ed errore di rango k . Sotto: imputazione con SVD iterativa e convergenza del punto fisso.

8 Interpretazione degli assi

Il nome di un asse si legge dai pesi (loadings) più grandi, positivi e negativi.

- **b_1 contatto $\leftrightarrow$ gioco al largo:** pesi positivi su ruck, placcaggi, touche; negativi su metri guadagnati, difensori battuti, calci. Piloni e seconde linee da una parte, ali ed estremo dall'altra.
- **b_2 portatore di palla $\leftrightarrow$ chi porta poco palla:** pesi positivi su portate, offload, difensori battuti. Dal lato opposto ci sono sia i registi sia i piloni: l'interpretazione iniziale “regista contro portatore” è stata corretta dai dati.

Osservazione. Gli assi descrivono **stili**, non livelli: uno score basso su b_1 per un'ala non indica una carenza. Per parlare di margini di miglioramento bisogna confrontare giocatori dello stesso ruolo (Sezione 10). Inoltre la terza componente è meno affidabile: $\lambda_3 = 1.05$ e $\lambda_4 = 0.73$ sono vicini, e un piccolo distacco tra autovalori rende l'autovettore sensibile al rumore dei dati.

9 Gruppi di lavoro bilanciati

Siano $\mathbf{z}_n \in \mathbb{R}^K$ gli score ($K = 3$), con media della squadra nulla. Si dividono i giocatori in $G = 5$ gruppi da 5; $\bar{\mathbf{z}}_g$ è la media del gruppo g e n_g il numero di giocatori.

Proposizione 1 (Decomposizione della varianza).

$$\underbrace{\sum_n \|\mathbf{z}_n\|^2}_{SS_{tot}} = \underbrace{\sum_g n_g \|\bar{\mathbf{z}}_g\|^2}_{SS_{tra}} + \underbrace{\sum_g \sum_{n \in g} \|\mathbf{z}_n - \bar{\mathbf{z}}_g\|^2}_{SS_{dentro}}.$$

Dimostrazione. Per ogni gruppo si scrive $\mathbf{z}_n = (\mathbf{z}_n - \bar{\mathbf{z}}_g) + \bar{\mathbf{z}}_g$ e si sviluppa il quadrato:

$$\sum_{n \in g} \|\mathbf{z}_n\|^2 = \sum_{n \in g} \|\mathbf{z}_n - \bar{\mathbf{z}}_g\|^2 + n_g \|\bar{\mathbf{z}}_g\|^2 + 2 \bar{\mathbf{z}}_g^T \sum_{n \in g} (\mathbf{z}_n - \bar{\mathbf{z}}_g).$$

L'ultima somma è nulla per definizione di media. Sommando sui gruppi si ottiene la tesi. $\square$

Obiettivo. SS_{tot} è fissata dai dati, quindi

$$\min SS_{tra} \iff \max SS_{dentro} :$$

gruppi con la stessa media della squadra sono, necessariamente, gruppi internamente vari, in cui giocatori forti e deboli su ogni asse sono mescolati. Gli assi non vanno ripesati: lo score lungo $\mathbf{b}_j$ ha già varianza λ_j .

Algoritmo di scambio. Si parte da una divisione casuale; si provano tutti gli scambi di due giocatori di gruppi diversi e si applica quello che diminuisce di più SS_{tra} ; ci si ferma quando nessuno scambio migliora. L'algoritmo trova un **minimo locale**: accetta solo scambi migliorativi e non può superare una configurazione in cui serve prima peggiorare. Le divisioni possibili sono circa $25!/((5!)^5 5!) \approx 5 \cdot 10^{12}$, troppe da esplorare; si usano 30 partenze casuali e si tiene la migliore.

Risultati. $SS_{tot} = 191.13$, $SS_{tra} = 0.30$ (0.16%), $SS_{dentro} = 190.83$; la somma verifica l'identità a 10^{-14} . Su 5000 divisioni casuali SS_{tra} ha media 31.7 e minimo 4.2 (Figura 4). SS_{tra} non arriva a 0 perché ogni gruppo dovrebbe avere media esattamente nulla su tutti e tre gli assi con esattamente 5 giocatori: in generale non è possibile.




Figura 4: Sinistra: giocatori nel piano $(\mathbf{b}_1, \mathbf{b}_2)$ colorati per gruppo; le X sono le medie dei gruppi, tutte vicine all'origine. Destra: SS_{tra} di 5000 divisioni casuali contro la divisione ottimizzata.

10 Direzioni di lavoro

Per ogni giocatore si confronta lo score con la media del suo ruolo. Su un asse j il verso tipico del ruolo è $s = \text{segno}(\bar{z}_{\text{ruolo},j})$; l'asse si usa solo se il ruolo sta chiaramente da una parte ($|\bar{z}_{\text{ruolo},j}| \geq$

$0.5\sqrt{\lambda_j}$). Il deficit è

$$d_j = s \frac{z_{n,j} - \bar{z}_{\text{ruolo},j}}{\sqrt{\lambda_j}},$$

e si segnala l'asse con deficit più negativo (sotto -0.25). Le statistiche da allenare sono quelle con peso grande nel verso s di $\mathbf{b}_j$ che il ruolo usa davvero e in cui il giocatore è sotto la media del ruolo; il mentore è il compagno di gruppo più forte su quelle statistiche. Esempio: Seconda linea 1, deficit -0.46 su $\mathbf{b}_1$, allenare ruck e placcaggi, mentore Terza linea 2.

11 Limiti

- Dati sintetici, $N = 25$: le componenti oltre la seconda sono poco affidabili (Sezione 6).
- L'algoritmo di scambio è un'euristica: nessuna garanzia di ottimo globale.
- La PCA descrive stili, non livelli: la direzione di lavoro richiede ipotesi aggiuntive (confronto con il ruolo).
- Sviluppi: dati reali di un campionato (assi stimati su molti giocatori, gruppi dentro una squadra); per N grande il prodotto $C\mathbf{v} = X^T(X\mathbf{v})/(N-1)$ evita di formare C .

References

- [1] M. P. Deisenroth, A. A. Faisal, C. S. Ong, *Mathematics for Machine Learning*, Cambridge University Press, 2020. Cap. 6 (statistiche riassuntive, geometria delle variabili aleatorie) e cap. 10 (PCA).